

# Aprendizado de Máquina

## Aula 2.1 - Algoritmos de Regressão


Adriano Rivolli

[rivolli@utfpr.edu.br](mailto:rivolli@utfpr.edu.br)

**Especialização em Inteligência Artificial**

Universidade Tecnológica Federal do Paraná (UTFPR)  
Câmpus Cornélio Procópio  
Departamento de Computação

# Conteúdo

- 
- 1 Introdução
  - 2 Regressão linear
  - 3 Regularização
  - 4 Regressão Polinomial

# Introdução

# Regressão

- Tarefa do aprendizado supervisionado
- O atributo alvo é um valor real
- É usada para prever o valor de uma **variável dependente** com base em uma ou mais **variáveis independentes**
- Explora o relacionamento entre as variáveis do problema

# Aplicações

- Previsão de custos, preços e vendas
- Estimativa de consumo e demanda
- Previsão de pontuação, crédito e taxas
- Preenchimento de valores ausentes

# Algoritmos

- **Regressão Linear**
- **Regressão Polinomial**
- Support Vector Regression
- Decision Tree Regression
- Random Forest Regression
- K-nearest neighbors regression

# Regressão linear

# Regressão Linear


- Assume que os dados (entrada/saída) são lineares ( **viés do algoritmo** )
- Aprende uma função linear que melhor aproxima a entrada em saída
- Há diferentes formas de estimar modelos lineares

Vamos conhecer o Mínimos Quadrados (*Least Squares*)




# Exemplo


Exemplo de Regressão Linear



Exemplo de Regressão Linear em Dados Não-Lineares



# Modelo


$$\hat{y} = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

- $\beta_0$  intercepto (também chamado de viés)
- $\beta_i$  coeficientes associados às variáveis preditivas
- $x$  é a instância que se deseja prever o valor de  $\hat{y}$
- O treinamento consiste em aprender os valores de  $\beta$

## Least Squares (exemplo)


- os coeficientes  $\beta$  são definidos visando diminuir a soma dos erros residuais

**RSS** = *Residual Sum-of-Squares*

$$\text{RSS}(\beta) = \sum_{i=1}^N (y_i - \hat{y})^2$$

$$\sum_{i=1}^N (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2$$

# Erros residuais



**Fonte:** Hastie, T., Tibshirani, R., Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.), pg. 45

## Interpretando os coeficientes

- $\beta_0$  **intercepto**: Valor predito quando todas as variáveis independentes são iguais a zero
- **Coefficientes**  $\beta_i$ : Cada coeficiente está associado a uma variável independente específica
  - ▶ Coeficiente positivo sugere que um aumento na variável independente está associado a um aumento no valor predito
  - ▶ Coeficiente negativo é o contrário
  - ▶ Valores próximos a 0 indicam que a variável independente em questão não possui relevância para a predição

## Erro padrão e Z-score

- Além dos valores dos coeficientes é possível entender a confiabilidade e significância estatística dos valores estimados
- **Std. Error (Erro Padrão):** Quanto menor, mais confiável é a estimativa do coeficiente
- **Z-score:** Valor absoluto maior que 1.96 indica que o coeficiente é estatisticamente significativo ao nível de significância de 5%

## Exemplo

Term	Coefficient	Std. Error	Z Score
Intercept	2.46	0.09	27.60
lcavol	0.68	0.13	5.37
lweight	0.26	0.10	2.75
age	-0.14	0.10	-1.40
lbph	0.21	0.10	2.06
svi	0.31	0.12	2.47
lcp	-0.29	0.15	-1.87
gleason	-0.02	0.15	-0.15
pgg45	0.27	0.15	1.74

**Fonte:** Hastie, T., Tibshirani, R., Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.), pg. 50

# Regularização



## Evitando overfitting

- A regularização é uma penalidade adicionada a função de custo
- Utilizada para controlar a magnitude dos coeficientes
- O seu uso faz com que o valor de alguns coeficientes sejam próximos de 0 (penaliza coeficientes grandes)
- Ajuda na seleção dos atributos mais relevantes

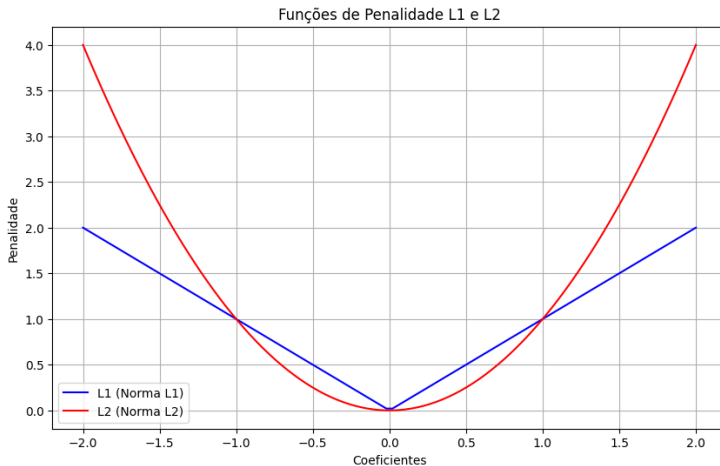
# Lasso

- *Least Absolute Shrinkage and Selection Operator*
- Útil para dados com alta dimensionalidade e atributos irrelevantes
- Utiliza a norma L1 (distância Manhattan)
- $Custo = RSS + \alpha \sum_{i=1}^p |\beta_i|$ 
  - ▶  $\alpha$  controla a força da regularização

# Ridge

- Útil para dados com atributos redundantes
- Utiliza a norma L2 (distância Euclidiana)
- $Custo = RSS + \alpha \sum_{i=1}^p \beta_i^2$ 
  - ▶  $\alpha$  controla a força da regularização

# L1 vs L2



## L1 vs L2 (características)

- **L1:** soma dos valores absolutos dos coeficientes
  - ▶ Tende a produzir coeficientes esparsos ( $\beta_i = 0$ )
  - ▶ Seleção de variáveis
- **L2:** soma dos quadrados dos coeficientes
  - ▶ Penalização suave e distribuída
  - ▶ Reduz a magnitude de todos os coeficientes proporcionalmente

## Regressão Polinomial

## Transformação dos dados


- Um caso especial de regressão linear
- Aplica-se um mapeamento dos dados
- O modelo se torna:

$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_n x^n$$

▶  $n$  é grau do polinômio

- É possível capturar relacionamentos mais complexos nos dados

# Dados polinomiais





## Atributos polinomiais

- Dado 2 atributos  $[a, b]$
- Aplicação da transformação polinomial de grau 2 resulta:
  - ▶  $[1, a, b, a^2, ab, b^2]$
- O número de atributos gerados é dado por:

$$\frac{(p + d)!}{p!d!},$$

onde  $p$  é o grau do polinômio e  $d$  o número de atributos

# A escolha do grau

